

Data Scientist : les fondamentaux

Jour 3 / 3 — Synthèse et mise en pratique en compétition

Auteur: Mouaad AGOURRAM

Objectifs et déroulé de la journée 3



Objectif du jour — consolider les acquis des deux premières journées, approfondir les points identifiés avec le formateur, puis se mesurer collectivement à une compétition en cours sur Kaggle, démarrée en fin de matinée par l'ensemble des participants.

Cette journée est entièrement consacrée à la pratique : elle repose directement sur les notions vues en jour 1 (modélisation, régression linéaire/logistique) et jour 2 (évaluation, nettoyage, feature engineering, méthodes ensemblistes).

01

Rappels et révisions

- Synthèse des points abordés en journées 1 et 2
- Approfondissement des sujets sélectionnés avec l'intervenant

Synthèse des points abordés en journée 1

Big Data & vocabulaire	5V, écosystème technologique, dataset / feature / target / training-test set
Modélisation d'un problème	Traduire une question métier en problème de classification ou de régression
Familles d'algorithmes	Supervisé (classification / régression) vs non supervisé (clustering, réduction de dimension)
Régression linéaire	Fonction hypothèse, fonction de coût convexe, descente de gradient
Régression logistique	Fonction sigmoïde, frontière de décision, log-loss
Outils	Python, Pandas, Scikit-learn — premier modèle sur le Titanic

Synthèse des points abordés en journée 2

Évaluer un modèle	Cross-validation, métriques : precision, recall, ROC/AUC, MAPE
Diagnostiquer	Overfitting / underfitting, compromis biais-variance, régularisation Ridge/Lasso
Nettoyer les données	Types de données, détection d'outliers, stratégies d'imputation des valeurs manquantes
Feature engineering	Encodage des variables catégorielles, création de variables discriminantes
Visualiser	Histogrammes, scatter plots, courbes train/test loss, feature importance
Méthodes ensemblistes	Arbre de décision, bagging (Random Forest), boosting, clustering, PCA, anomalies

Approfondissement des sujets sélectionnés avec l'intervenant

Principe — à partir des difficultés et des questions rencontrées lors des TP des jours 1 et 2, le formateur sélectionne avec le groupe les notions à retravailler en profondeur avant la mise en pratique de l'après-midi.



Réglage des hyperparamètres

Approfondir le choix du taux d'apprentissage, du paramètre de régularisation λ , ou de la profondeur d'un arbre.



Feature engineering avancé

Revenir sur la création de variables discriminantes propres au dataset ou au métier des participants.



Choix de la métrique

Retravailler l'arbitrage precision/recall selon un cas métier apporté par un participant.



Méthodes ensemblistes

Détailler davantage bagging vs boosting sur des exemples concrets du groupe.

Ce temps d'échange est volontairement piloté par les besoins exprimés par les participants pendant les deux premières journées.

02

Mise en pratique

- Le dernier jour est entièrement consacré à des mises en pratique
- Sélection et participation à une compétition

Mise en pratique



Ce que chaque participant met en œuvre

- Reprendre son propre pipeline (nettoyage → feature engineering → modélisation → évaluation)
- Tester plusieurs algorithmes vus en formation (régression logistique, arbres, méthodes ensemblistes)
- Utiliser la cross-validation pour comparer objectivement les variantes testées
- Soumettre plusieurs versions et suivre l'évolution du score au fil des itérations

Sélection et participation à une compétition

Principe — le formateur sélectionne une compétition en cours sur Kaggle, qui sera démarrée en journée 3 par l'ensemble des participants.



Objectif pédagogique : appliquer, en autonomie et en conditions réelles, l'ensemble de la méthodologie vue durant les trois jours de formation.

Bilan de fin de formation

- Retour collectif sur les scores obtenus et les approches testées par chacun
- Auto-évaluation des connaissances et compétences vis-à-vis des objectifs pédagogiques annoncés en jour 1

Aller plus loin : stacking et blending de modèles

Principe — combiner les prédictions de plusieurs modèles différents (régression logistique, Random Forest, Gradient Boosting...) améliore souvent la performance au-delà de chaque modèle pris isolément.



Blending

Moyenne (simple ou pondérée) des prédictions de plusieurs modèles entraînés indépendamment — rapide à mettre en œuvre.



Stacking

Un méta-modèle apprend à combiner de façon optimale les prédictions des modèles de base, souvent via cross-validation pour éviter la fuite de données.

Sur une compétition Kaggle, ces techniques permettent souvent de gagner quelques dixièmes de point supplémentaires une fois les modèles de base bien réglés individuellement — à réserver après avoir consolidé une bonne baseline.

Grille de lecture d'un leaderboard Kaggle

Leaderboard public	Calculé sur une partie du jeu de test, visible en temps réel pendant la compétition.
Leaderboard privé	Calculé sur l'autre partie du jeu de test, révélé seulement à la clôture — c'est le classement qui compte réellement.
Overfitting au leaderboard public	Risque de sur-optimiser un modèle pour le score public au détriment de sa capacité de généralisation.

Bonne pratique

- Se fier avant tout à son propre score de cross-validation, plus stable que le seul score public, pour comparer ses itérations
- Considérer le score public comme un indicateur parmi d'autres, pas comme l'unique juge de la qualité d'un modèle

Check-list avant soumission finale

- 1 Le pipeline de prétraitement est-il identique entre entraînement et prédiction (pas de fuite de données) ?
- 2 Le score de cross-validation est-il cohérent avec le score observé sur le leaderboard public ?
- 3 Le random_state / seed est-il fixé pour garantir la reproductibilité des résultats ?
- 4 Le fichier de soumission respecte-t-il exactement le format attendu (colonnes, ordre, types) ?
- 5 A-t-on conservé une trace des expériences menées (features testées, scores obtenus) pour pouvoir comparer et itérer ?

Les trois jours de formation en un coup d'œil

1

Jour 1

Big Data, modélisation, régression linéaire/logistique, 1er modèle Titanic

2

Jour 2

Évaluation, nettoyage, feature engineering, méthodes ensemblistes

3

Jour 3

Synthèse, approfondissement, compétition en autonomie

Le fil rouge méthodologique

- Comprendre le problème métier et le traduire en problème de Data Science
- Préparer et enrichir les données (nettoyage, feature engineering)
- Modéliser, évaluer rigoureusement (cross-validation, métriques adaptées), puis itérer
- Ce même cycle s'applique à tout projet de Data Science, bien au-delà du cas Titanic

Pour aller plus loin après la formation



Pratiquer

Continuer sur Kaggle avec d'autres jeux de données et compétitions « Getting Started ».



Approfondir

Explorer le deep learning, le traitement du langage naturel ou les séries temporelles selon vos besoins métier.



Industrialiser

Se former au déploiement de modèles (API, MLOps, monitoring) pour passer du prototype à la production.

L'objectif de cette formation était de poser des bases solides et une méthodologie reproductible : le reste s'apprend surtout par la pratique, projet après projet.

Q3

QCM — Jour 3

- 8 questions de synthèse sur l'ensemble de la formation
- La réponse s'affiche au clic, juste après chaque question

Face à une nouvelle compétition Kaggle, quelle est la première étape méthodologique recommandée ?

- A** Entraîner immédiatement le modèle le plus complexe possible
 - B** Lire l'énoncé pour comprendre la target et la métrique de classement, puis explorer les données
 - C** Soumettre un fichier vide pour tester le format attendu
 - D** Ignorer les valeurs manquantes tant qu'aucune erreur n'apparaît
- Bonne réponse : B.**
- ✓ Comme vu tout au long de la formation, la modélisation part toujours de la compréhension du problème métier (target, métrique) avant toute exploration puis modélisation.

Pourquoi construit-on d'abord une « baseline » simple avant d'itérer sur un modèle plus complexe ?

- A Parce que les modèles complexes sont interdits en compétition
- B Pour disposer d'un point de comparaison fiable et mesurer objectivement chaque amélioration
- C Parce qu'une baseline n'a pas besoin d'être évaluée
- D Pour éviter d'avoir à nettoyer les données

Bonne réponse : B.



Une baseline sert de référence : chaque nouvelle itération (feature engineering, autre algorithme, réglage d'hyperparamètres) est comparée à ce point de départ pour vérifier qu'elle apporte un réel gain.

Sur les trois jours de formation, quel est l'ordre logique du pipeline appliqué au cas Titanic ?

A

Modélisation → nettoyage → collecte → feature engineering

B

Compréhension du problème → nettoyage/feature engineering → modélisation → évaluation → itération

C

Soumission Kaggle → exploration des données → nettoyage

D

Évaluation → collecte des données → modélisation

✓

Bonne réponse : B.

C'est le fil rouge suivi depuis le jour 1 (poser le problème) jusqu'au jour 3 (itérer en compétition) : comprendre, préparer les données, modéliser, évaluer, puis recommencer.

En cross-validation, à quoi sert de comparer plusieurs algorithmes (ex. régression logistique vs Random Forest) sur les mêmes folds ?

- A À garantir que le modèle le plus complexe est toujours le meilleur
- B À comparer objectivement leur performance sur des données identiques et non vues à l'entraînement
- C À remplacer le besoin de nettoyer les données
- D À éviter d'avoir à choisir une métrique d'évaluation

Bonne réponse : B.

- ✓ Utiliser les mêmes folds de cross-validation pour chaque algorithme permet une comparaison équitable, sans biais lié à un découpage différent des données.

Quel est l'objectif principal du temps d'approfondissement en début de journée 3 ?

- A** Introduire une toute nouvelle famille d'algorithmes non vue en jours 1-2
- B** Retravailler en profondeur les notions et difficultés identifiées par les participants durant les jours 1 et 2
- C** Remplacer la compétition de l'après-midi
- D** Évaluer individuellement chaque participant par un examen noté

 **Bonne réponse : B.**
L'approfondissement du jour 3 est piloté par les besoins exprimés pendant les TP précédents — il consolide les acquis avant la mise en pratique complète en compétition.

À l'issue de la compétition du jour 3, quelle démarche permet de mesurer sa progression sur cette compétition ?

A Comparer son score de fin de compétition à sa toute première soumission de cette même compétition

B Se fier uniquement à son ressenti, sans mesure chiffrée

C Ignorer le score et ne retenir que le classement

D Recommencer la formation depuis le jour 1

Bonne réponse : A.

✓ Suivre l'évolution du score entre la première soumission (baseline) et les versions itérées permet de mesurer concrètement l'impact des techniques apprises (nettoyage, feature engineering, choix d'algorithme).

Quelle est la différence entre le leaderboard public et le leaderboard privé sur Kaggle ?

- ☐ A Il n'y a aucune différence, ce sont les mêmes données
- ☒ B Le public est calculé sur une partie du test set et visible en direct ; le privé, sur l'autre partie, détermine le classement final
- ☐ C Le privé n'est visible que par les organisateurs avant la compétition
- ☐ D Le public sert uniquement à valider le format du fichier de soumission

☒ **Bonne réponse : B.**
Cette séparation protège contre le sur-ajustement au score public : un modèle trop optimisé pour le leaderboard public peut se révéler moins bon sur le leaderboard privé, qui fixe le classement définitif.

Quelle différence caractérise le stacking par rapport au blending ?

- ☒ A Le stacking utilise un méta-modèle pour combiner les prédictions des modèles de base, le blending se contente d'une moyenne simple ou pondérée
- ☐ B Le blending nécessite obligatoirement un réseau de neurones
- ☐ C Le stacking ne fonctionne qu'avec un seul modèle de base
- ☐ D Il n'existe aucune différence entre les deux termes

Bonne réponse : A.

- ☒ Le blending agrège directement les prédictions (moyenne simple/pondérée), tandis que le stacking entraîne un modèle supplémentaire (le méta-modèle) à apprendre la meilleure combinaison possible de ces prédictions.